HỌC SÂU

BÀI 4. MẠNG NƠ-RON TÍCH CHẬP (CNN)

Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là một loại mạng nơ-ron đặc biệt được thiết kế để xử lý dữ liệu có cấu trúc lưới, đặc biệt là hình ảnh. CNN đã trở thành công nghệ nền tảng trong lĩnh vực thị giác máy tính (Computer Vision) và nhiều ứng dụng xử lý hình ảnh khác.

1.1. Tại sao cần CNN?

Mạng nơ-ron thông thường (Fully Connected Neural Network) gặp phải một số hạn chế khi xử lý hình ảnh:

- **Số lượng tham số lớn**: Một hình ảnh nhỏ 28x28 pixel đã cần 784 nơ-ron đầu vào
- **Không bảo toàn thông tin không gian**: Mất đi mối quan hệ giữa các pixel lân cận
- **Không bất biến với dịch chuyển**: Không nhận dạng được đối tượng khi vị trí thay đổi

CNN giải quyết những vấn đề này bằng cách:

- Sử dụng các bộ lọc (filter) nhỏ thay vì kết nối đầy đủ
- Bảo toàn thông tin không gian thông qua cấu trúc lưới
- Tạo ra tính bất biến dịch chuyển (translation invariance)

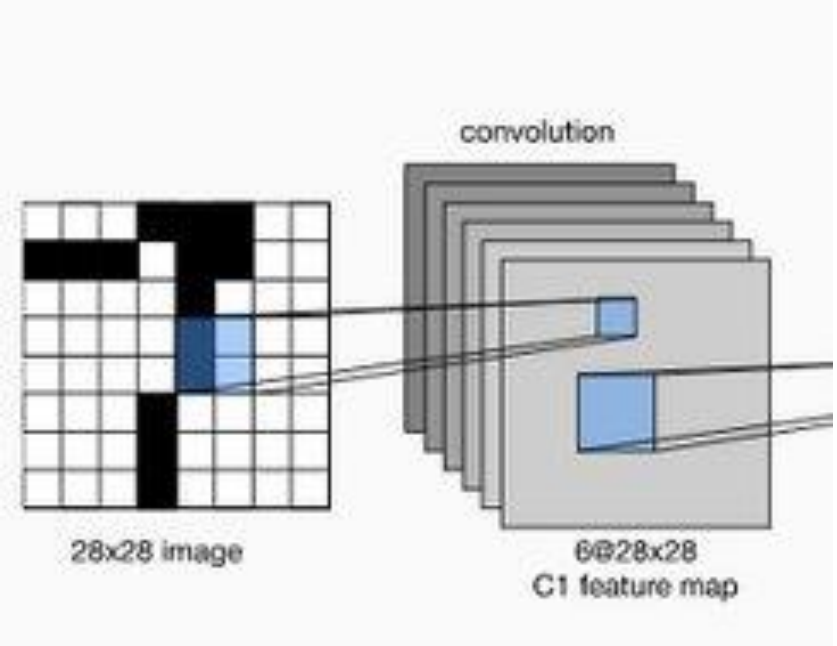

2. Cấu trúc của mạng CNN

Một mạng CNN điển hình bao gồm các lớp sau:

- Lớp tích chập (Convolutional Layer)
- Hàm kích hoạt (Activation Function)
- Lớp gộp (Pooling Layer)
- Lớp Dropout
- Lớp kết nối đầy đủ (Fully Connected Layer)

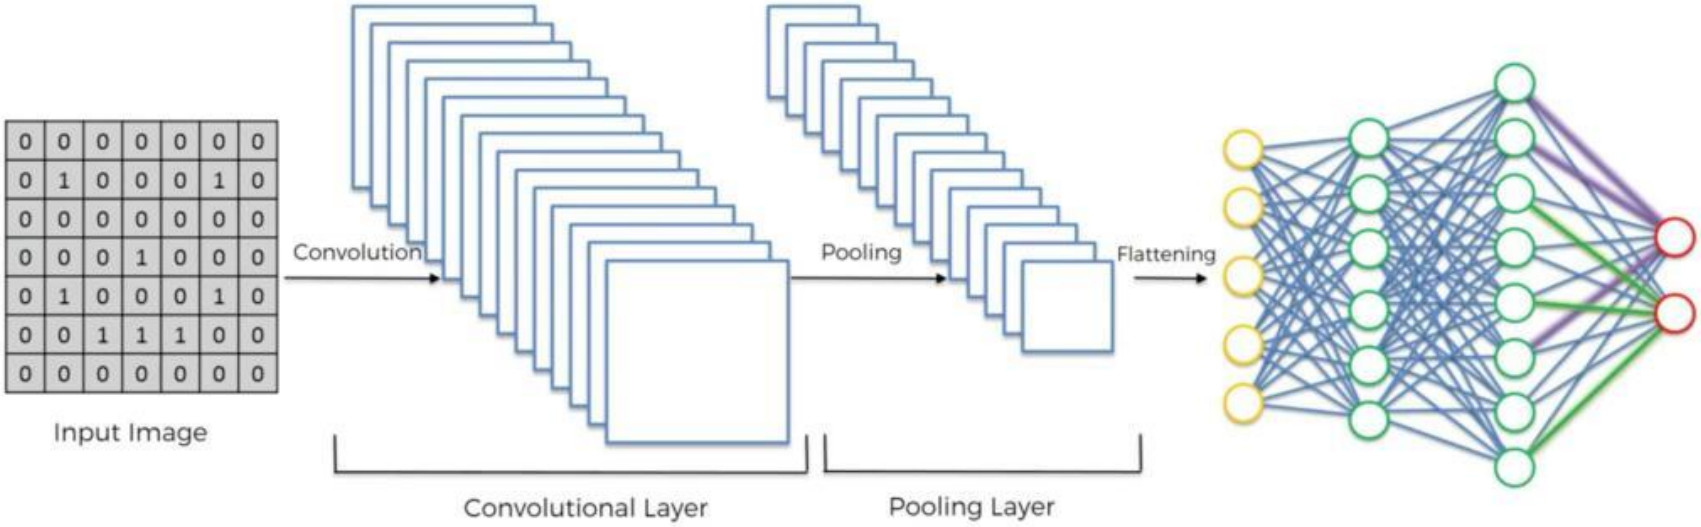

2.1. Phép tích chập

Phép tích chập

- Sử dụng các bộ lọc (kernel/filter) nhỏ (thường là 3x3 hoặc 5x5)
- Trượt (slide) bộ lọc qua toàn bộ hình ảnh đầu vào
- Tại mỗi vị trí, thực hiện phép tích chập: nhân từng phần tử của bộ lọc với vùng tương ứng trên hình ảnh và cộng lại

Bộ lọc

Bộ lọc (hay còn gọi là kernel hoặc filter) trong mạng nơ-ron tích chập (CNN) là một ma trận nhỏ với các trọng số (weight) mà mạng nơ-ron học được trong quá trình huấn luyện. Đây là một khái niệm cốt lõi trong CNN, thực hiện chức năng trích xuất đặc trưng từ dữ liệu đầu vào.

Bộ lọc là một ma trận nhỏ (thường có kích thước 3x3, 5x5, hoặc 7x7) chứa các giá trị trọng số.

Filter

1	0	-1
1	0	-1
1	0	-1

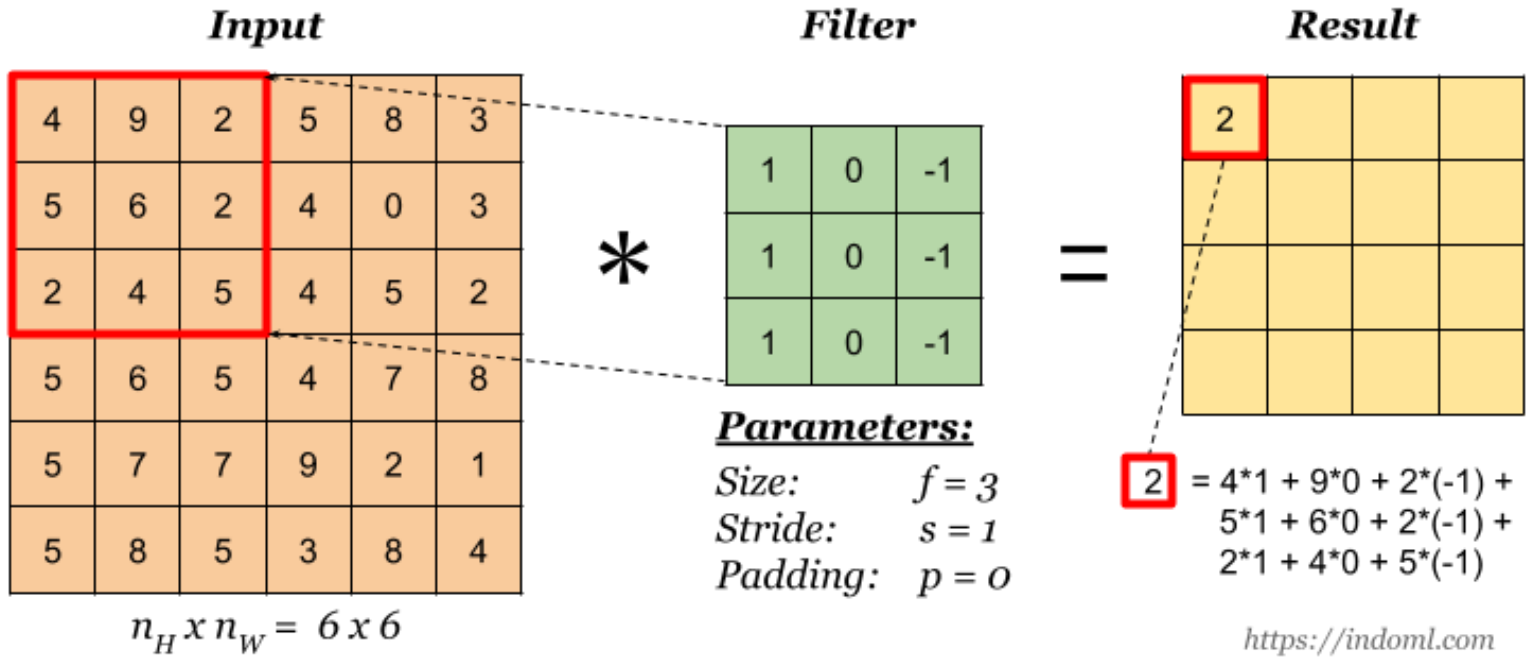
Input
Filter
Result
4 9 2 5 8 3
5 6 2 4 0 3
2 4 5 4 5 2
5 6 5 4 7 8
5 7 7 9 2 1
5 8 5 3 8 4
*
1 0 -1
1 0 -1
1 0 -1
=
2
Parameters:
Size: f = 3
Stride: s = 1
Padding: p = 0
2 = 4*1 + 9*0 + 2*(-1) +
5*1 + 6*0 + 2*(-1) +
2*1 + 4*0 + 5*(-1)
n_H x n_W = 6 x 6
https://indoml.com

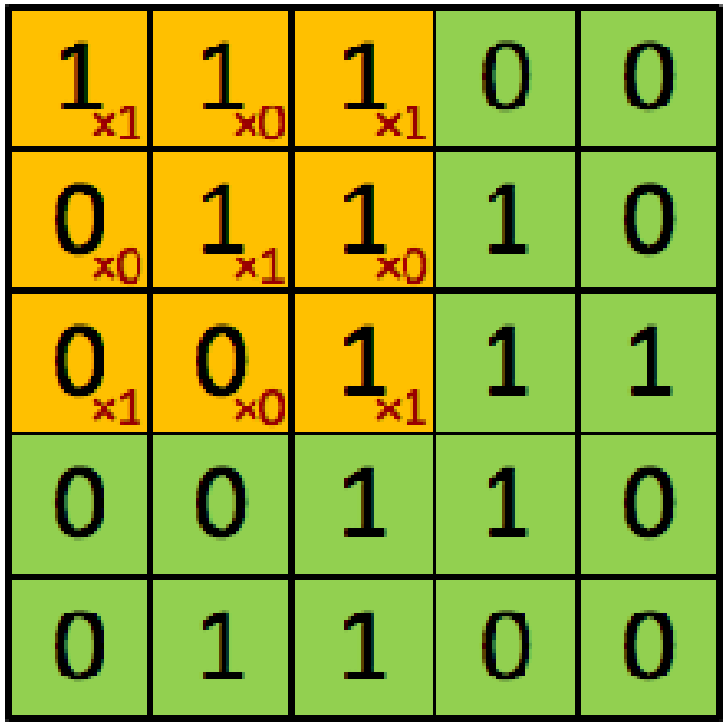

Image

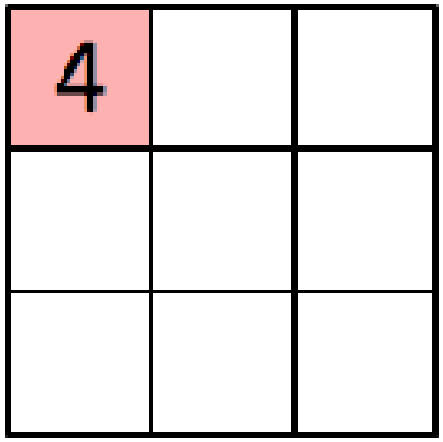

Convolved Feature

Bộ lọc

- Mỗi bộ lọc được thiết kế để phát hiện một đặc trưng cụ thể trong hình ảnh
- Các bộ lọc ở tầng đầu thường phát hiện đặc trưng đơn giản như cạnh, góc, đường thẳng
- Các bộ lọc ở tầng sau phát hiện đặc trưng phức tạp hơn như mắt, mũi, bánh xe, v.v.

Stride (Bước nhảy)

Stride là khoảng cách (số pixel) mà bộ lọc di chuyển sau mỗi lần tính toán trong quá trình tích chập.

- **Stride = 1**: Bộ lọc di chuyển 1 pixel mỗi lần (tiêu chuẩn)
- **Stride = 2**: Bộ lọc di chuyển 2 pixel mỗi lần (giảm kích thước đầu ra)

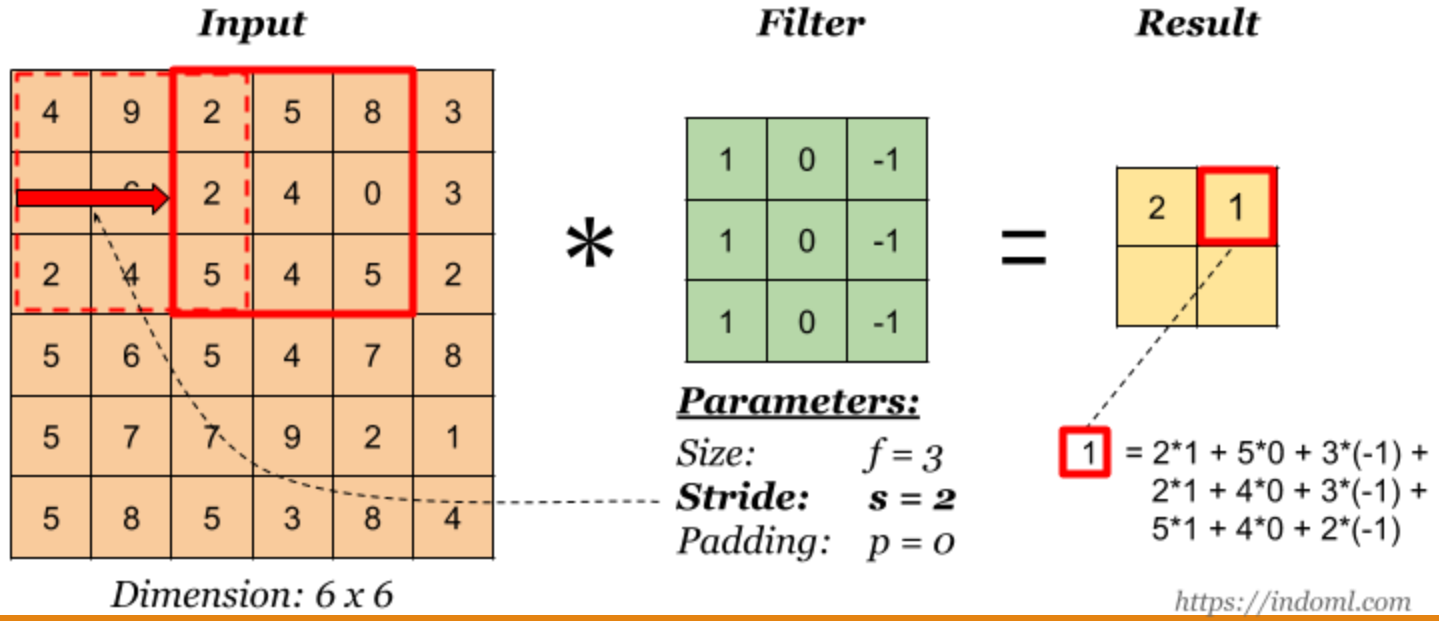

Stride (Bước nhảy)

Ảnh hưởng của stride:

- Stride lớn hơn giúp giảm kích thước đầu ra (downsampling)
- Giảm thời gian tính toán
- Có thể làm mất thông tin nếu stride quá lớn

Padding (Đệm)

Padding là quá trình thêm các pixel (thường là 0) xung quanh biên của hình ảnh đầu vào.

Mục đích của padding:

1. Giữ nguyên kích thước đầu ra sau phép tích chập
2. Giữ lại thông tin ở biên của ảnh đầu vào

Các loại padding:

- **Valid padding** (không padding): Kích thước đầu ra nhỏ hơn đầu vào
- **Same padding**: Thêm đủ padding để kích thước đầu ra bằng đầu vào

0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

Kernel

0	-1	0
-1	5	-1
0	-1	0

114				

2.2. Phép tính chập với dữ liệu có nhiều kênh chiều sâu

Trong thực tế, hình ảnh thường có nhiều kênh màu (ví dụ: RGB có 3 kênh).

CNN xử lý dữ liệu đa kênh thông qua bộ lọc có cùng số kênh với đầu vào.

2.2. Phép tính chập với dữ liệu có nhiều kênh chiều sâu

Nguyên lý hoạt động:
1.Đầu vào đa kênh: Ví dụ, ảnh RGB có 3 kênh (kênh đỏ, kênh xanh lá, kênh xanh dương), mỗi kênh là một ma trận 2D.

2.Bộ lọc đa kênh: Mỗi bộ lọc cũng có 3 kênh, tương ứng với 3 kênh của đầu vào.

3.Cách tính:

1. Thực hiện phép tích chập riêng biệt giữa mỗi kênh của đầu vào với kênh tương ứng của bộ lọc
2. Cộng tất cả kết quả lại để tạo ra một feature map đầu ra duy nhất

2.2. Phép tính chập với dữ liệu có nhiều kênh chiều sâu

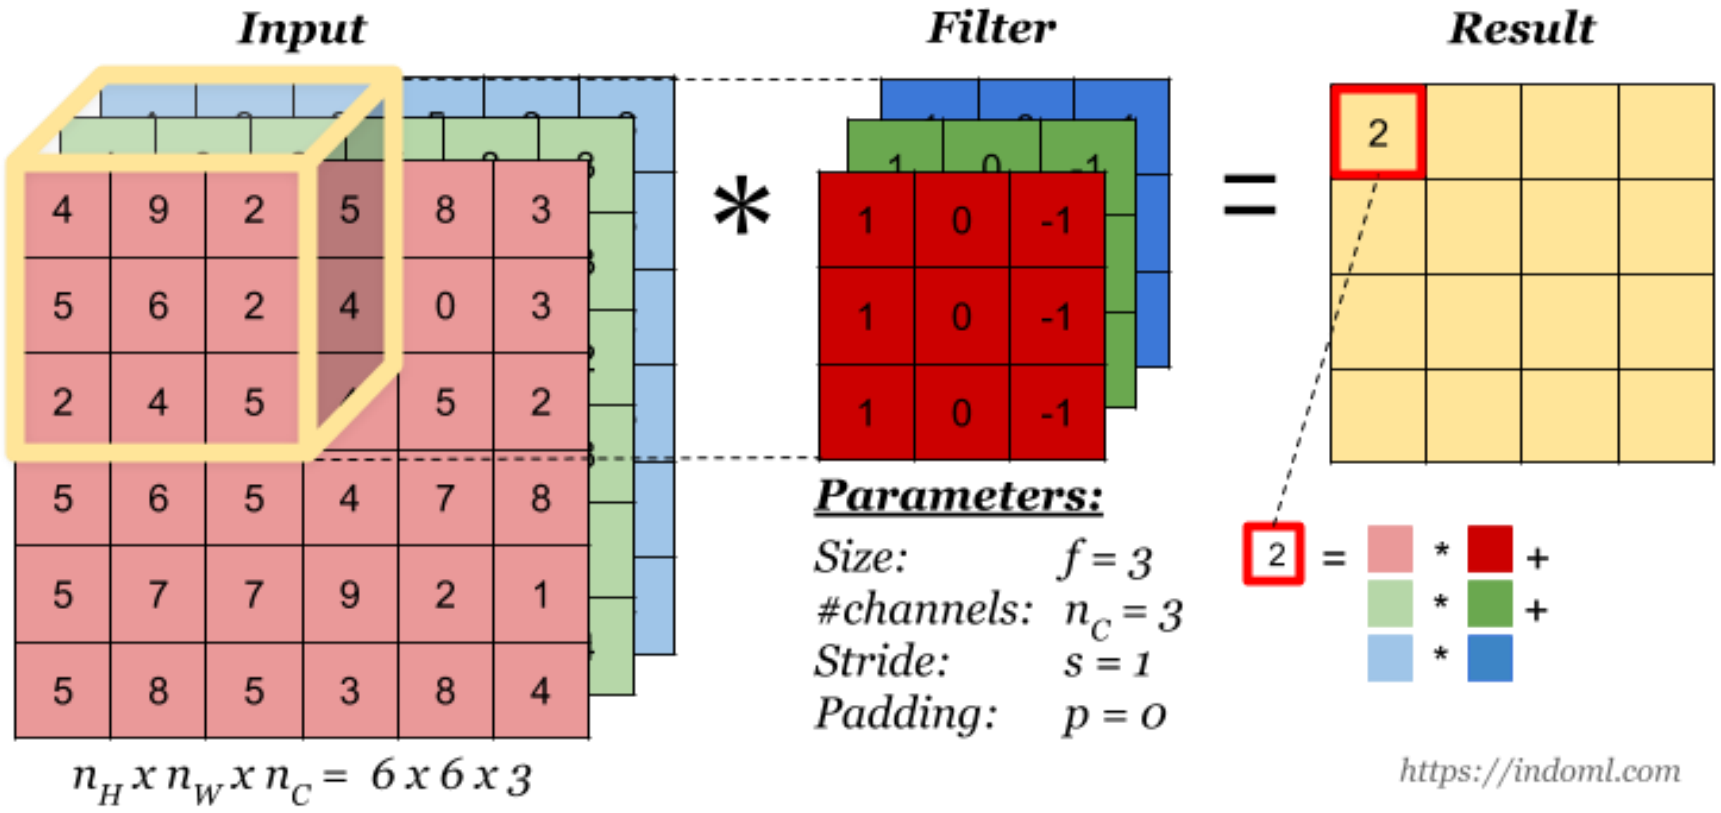

```
Kênh R:          Kênh G:          Kênh B:
1  2  3  4  5    5  6  7  8  9    9  8  7  6  5
6  7  8  9  10   10 11 12 13 14   4  3  2  1  0
11 12 13 14 15   15 16 17 18 19   1  2  3  4  5
16 17 18 19 20   20 21 22 23 24   6  7  8  9  10
21 22 23 24 25   25 26 27 28 29   11 12 13 14 15
```

```
Kênh R:       Kênh G:       Kênh B:
1  0  1       0  1  0       1  0  1
0  1  0       1  0  1       0  1  0
1  0  1       0  1  0       1  0  1
```

Đầu ra tại vị trí (0,0) sẽ là tổng của 3 phép tích chập:

- Tích chập kênh R: (1×1) + (2×0) + ... = 35
- Tích chập kênh G: (5×0) + (6×1) + ... = 48
- Tích chập kênh B: (9×1) + (8×0) + ... = 31
- Tổng: 35 + 48 + 31 = 114

2.3. Phép tính chập với nhiều bộ lọc

Trong CNN thực tế, một lớp tích chập thường sử dụng nhiều bộ lọc khác nhau để trích xuất nhiều loại đặc trưng khác nhau từ dữ liệu đầu vào.

Nguyên lý hoạt động:

1. **Nhiều bộ lọc, mỗi bộ lọc có cùng kích thước**: Mỗi lớp tích chập thường có nhiều bộ lọc (từ vài chục đến hàng trăm).
2. **Mỗi bộ lọc tạo ra một feature map**: Khi áp dụng n bộ lọc, ta sẽ thu được n feature map đầu ra.
3. **Mỗi bộ lọc phát hiện một loại đặc trưng khác nhau**: Ví dụ, một bộ lọc có thể phát hiện cạnh ngang, bộ lọc khác phát hiện cạnh dọc, góc, hoa văn...

2.3. Phép tính chập với nhiều bộ lọc

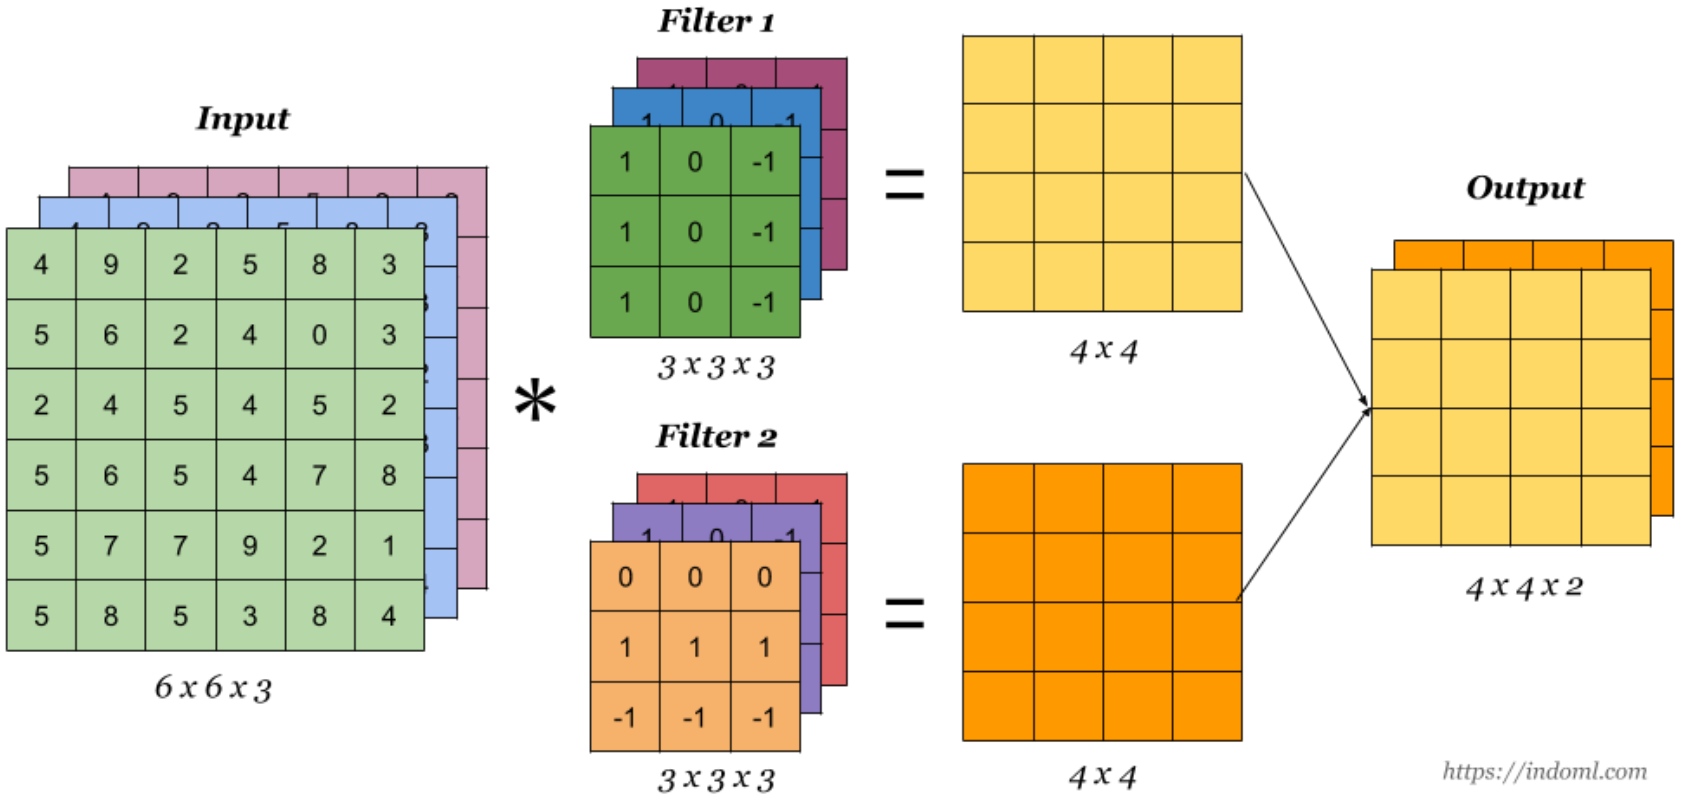

2.3. Phép tính chập với nhiều bộ lọc

Ý nghĩa và lợi ích:

1. **Phát hiện nhiều đặc trưng khác nhau**: Mỗi bộ lọc chuyên biệt phát hiện một loại mẫu cụ thể trong dữ liệu.
2. **Tạo ra biểu diễn phong phú**: Tập hợp các feature map cung cấp biểu diễn đa chiều về dữ liệu đầu vào.
3. **Học phân cấp đặc trưng**: Các lớp tích chập sâu hơn có thể kết hợp các đặc trưng cơ bản từ các lớp trước để phát hiện các mẫu phức tạp hơn.
4. **Tạo cơ sở cho việc phân loại**: Các feature map cuối cùng chứa thông tin đủ để lớp fully connected có thể thực hiện phân loại chính xác.

2.4. Lớp tích chập

Lớp tích chập là một lớp trong CNN thực hiện các phép toán tích chập giữa dữ liệu đầu vào và các bộ lọc (filter/kernel) để tạo ra các bản đồ đặc trưng (feature map).

Đây là lớp chịu trách nhiệm chính trong việc học và trích xuất các đặc trưng từ dữ liệu.

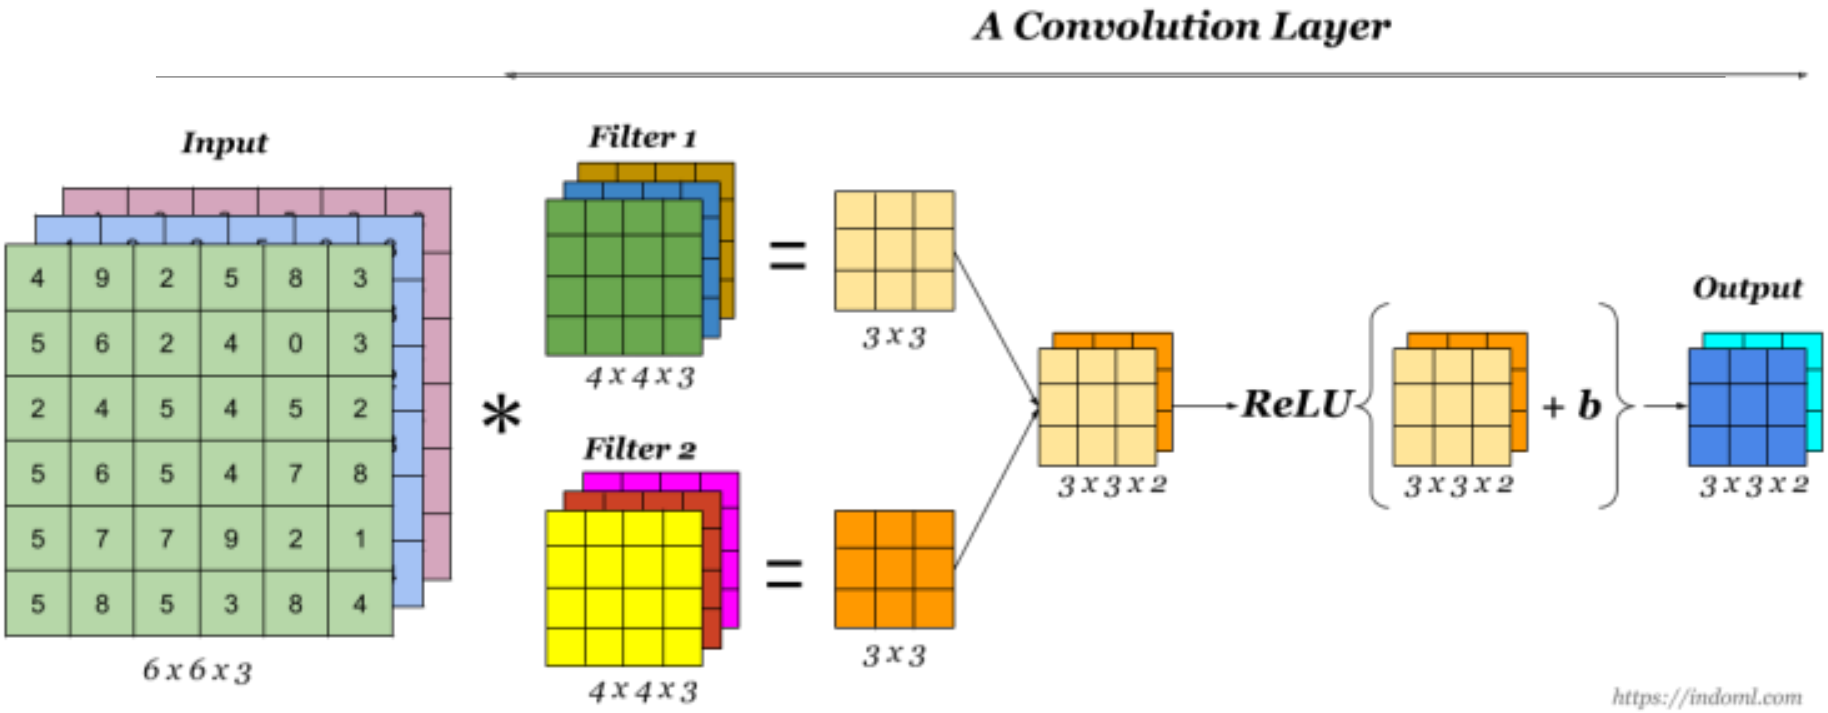
A Convolution Layer
Input
4 9 2 5 8 3
5 6 2 4 0 3
2 4 5 4 5 2
5 6 5 4 7 8
5 7 7 9 2 1
5 8 5 3 8 4
6 x 6 x 3
*
Filter 1
4 x 4 x 3
=
3 x 3
Filter 2
4 x 4 x 3
=
3 x 3
3 x 3 x 2
ReLU
3 x 3 x 2
+ b
Output
3 x 3 x 2
https://indoml.com

2.5. Lớp pooling

Lớp Pooling là gì?

Lớp gộp (Pooling) là một lớp trong CNN có nhiệm vụ giảm kích thước (downsampling) các feature map, giúp:

- Giảm số lượng tham số và tính toán trong mạng
- Kiểm soát overfitting
- Tăng tính bất biến với các biến đổi nhỏ trong dữ liệu đầu vào

Max Pooling

•**Nguyên lý**: Chọn giá trị lớn nhất trong một vùng

•**Cách hoạt động**: Chia feature map thành các vùng không chồng lấp, lấy giá trị max trong mỗi vùng

•**Ví dụ** với Max Pooling 2×2, stride=2

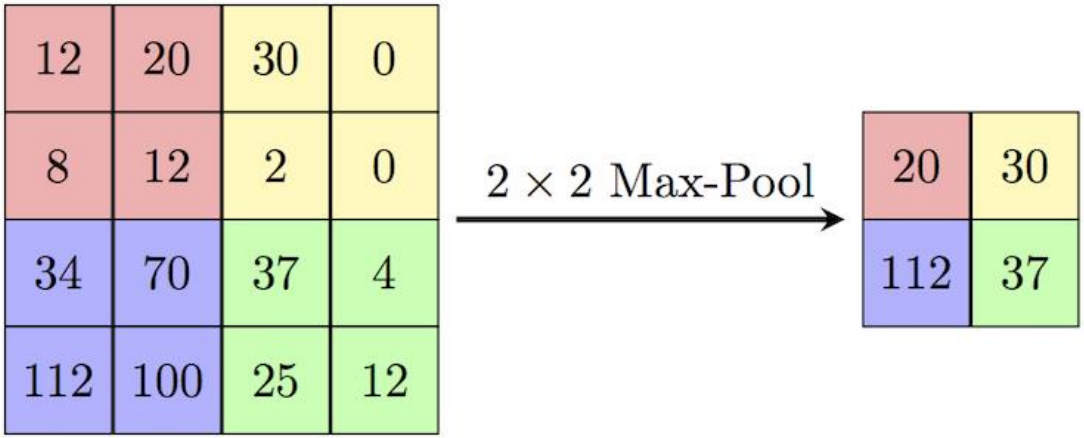

Ưu điểm: Giữ lại các đặc trưng nổi bật nhất, thường cho kết quả tốt trong nhận dạng hình ảnh

Average Pooling

- **Nguyên lý**: Tính giá trị trung bình trong một vùng
- **Cách hoạt động**: Tương tự Max Pooling nhưng lấy giá trị trung bình
- **Ví dụ** với Average Pooling 2×2, stride=2:

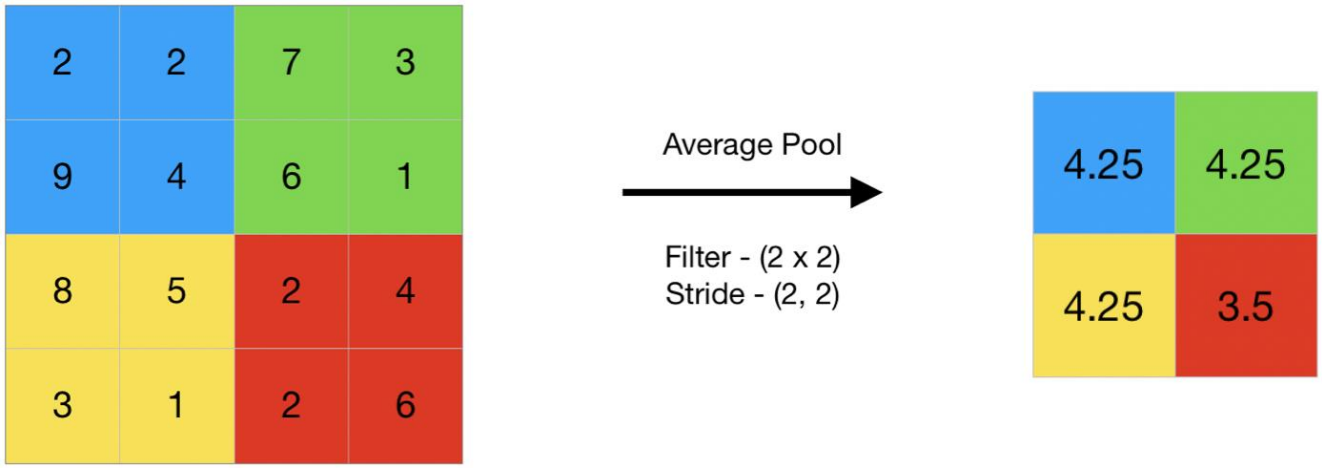

Ưu điểm: Giữ lại thông tin nền, có ích khi xử lý hình ảnh mịn, ảnh y tế

2.6. Lớp kết nối đầy đủ

Lớp kết nối đầy đủ (Fully Connected Layer) là một thành phần quan trọng trong kiến trúc mạng nơ-ron tích chập (CNN), thường được đặt ở các tầng cuối của mạng.

Lớp này kết nối mọi nơ-ron trong tầng hiện tại với mọi nơ-ron trong tầng trước đó, tương tự như trong mạng nơ-ron truyền thống (MLP).

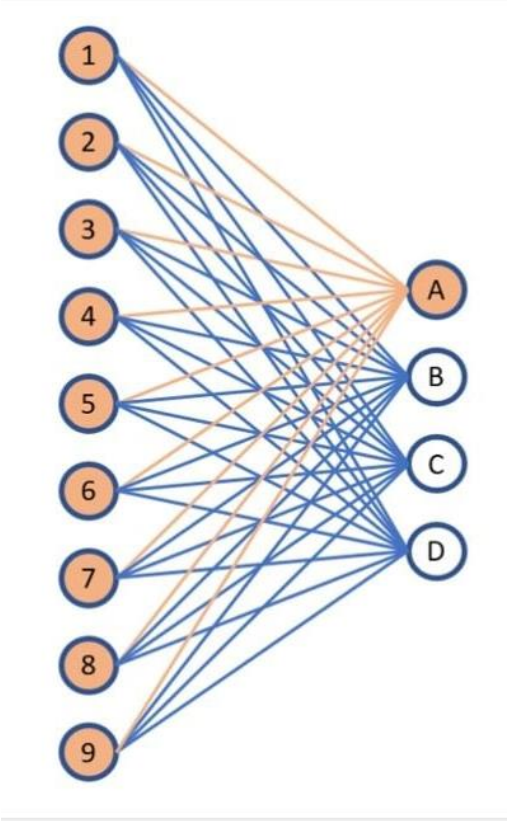

2.6. Lớp kết nối đầy đủ

Trong CNN điển hình, cấu trúc thường là:

1. Nhiều lớp tích chập (Convolutional Layers) + lớp gộp (Pooling Layers) → trích xuất đặc trưng
2. Lớp làm phẳng (Flatten Layer) → chuyển đổi feature maps thành vector
3. **Lớp kết nối đầy đủ (Fully Connected Layers)** → phân loại/dự đoán

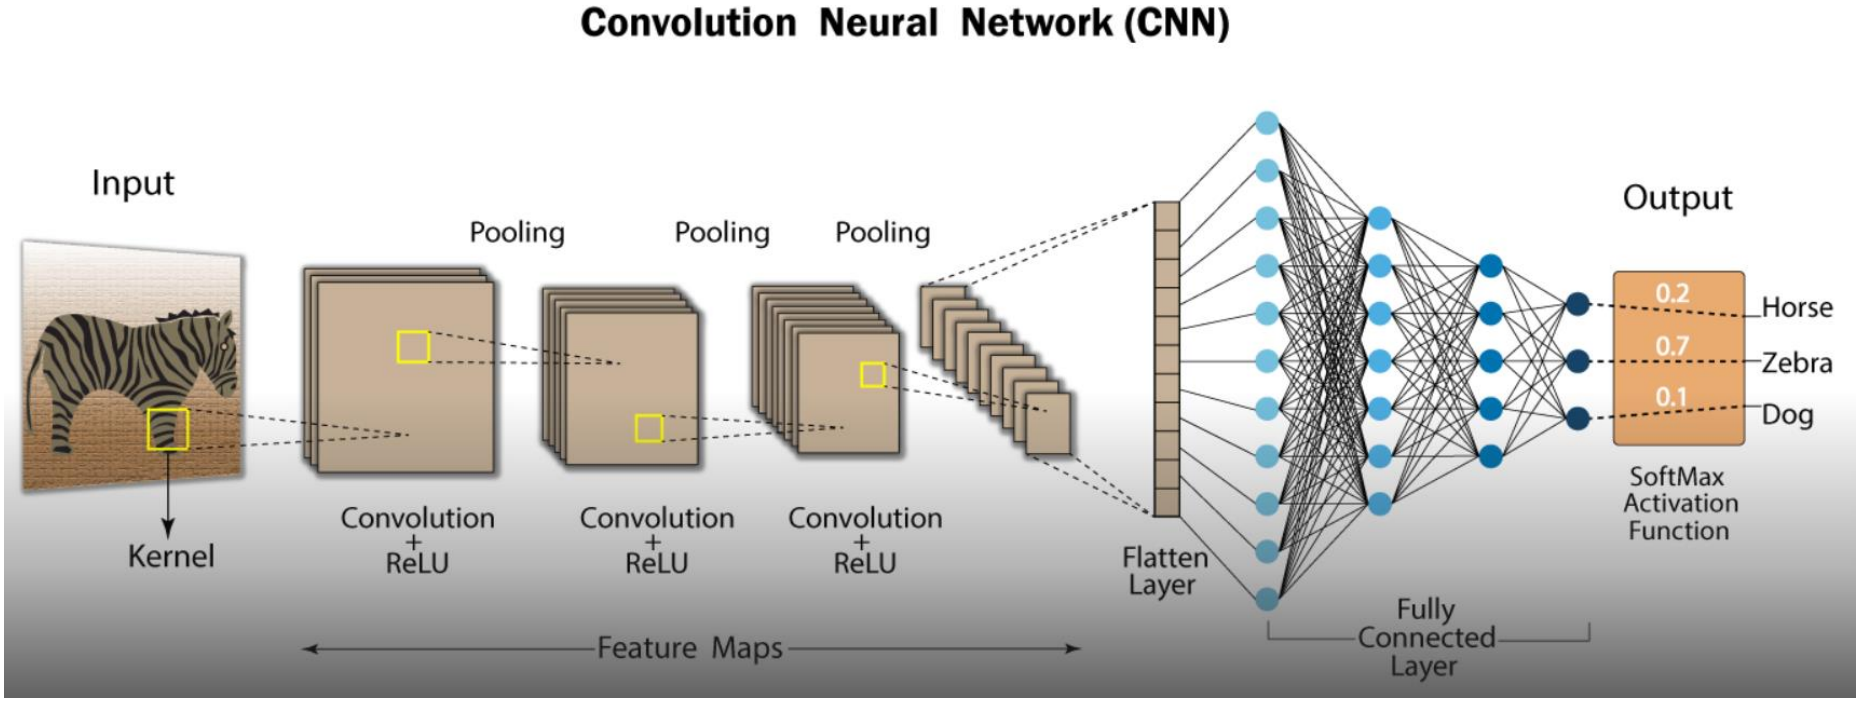
Convolution Neural Network (CNN)
Input
Pooling
Pooling
Pooling
Output
0.2
Horse
0.7
Zebra
0.1
Dog
Kernel
Convolution + ReLU
Convolution + ReLU
Convolution + ReLU
Flatten Layer
SoftMax Activation Function
Feature Maps
Fully Connected Layer

3. MỘT SỐ KIẾN TRÚC MẠNG CNN NỔI TIẾNG

LeNet

Người phát triển: Yann LeCun

Đặc điểm chính:

- Kiến trúc CNN đầu tiên, phát triển để nhận dạng chữ số viết tay
- 7 lớp (không tính đầu vào): 2 lớp tích chập, 2 lớp gộp (subsampling), 3 lớp kết nối đầy đủ
- Số tham số: khoảng 60,000
- Kích thước đầu vào: 32×32 pixel (ảnh xám)

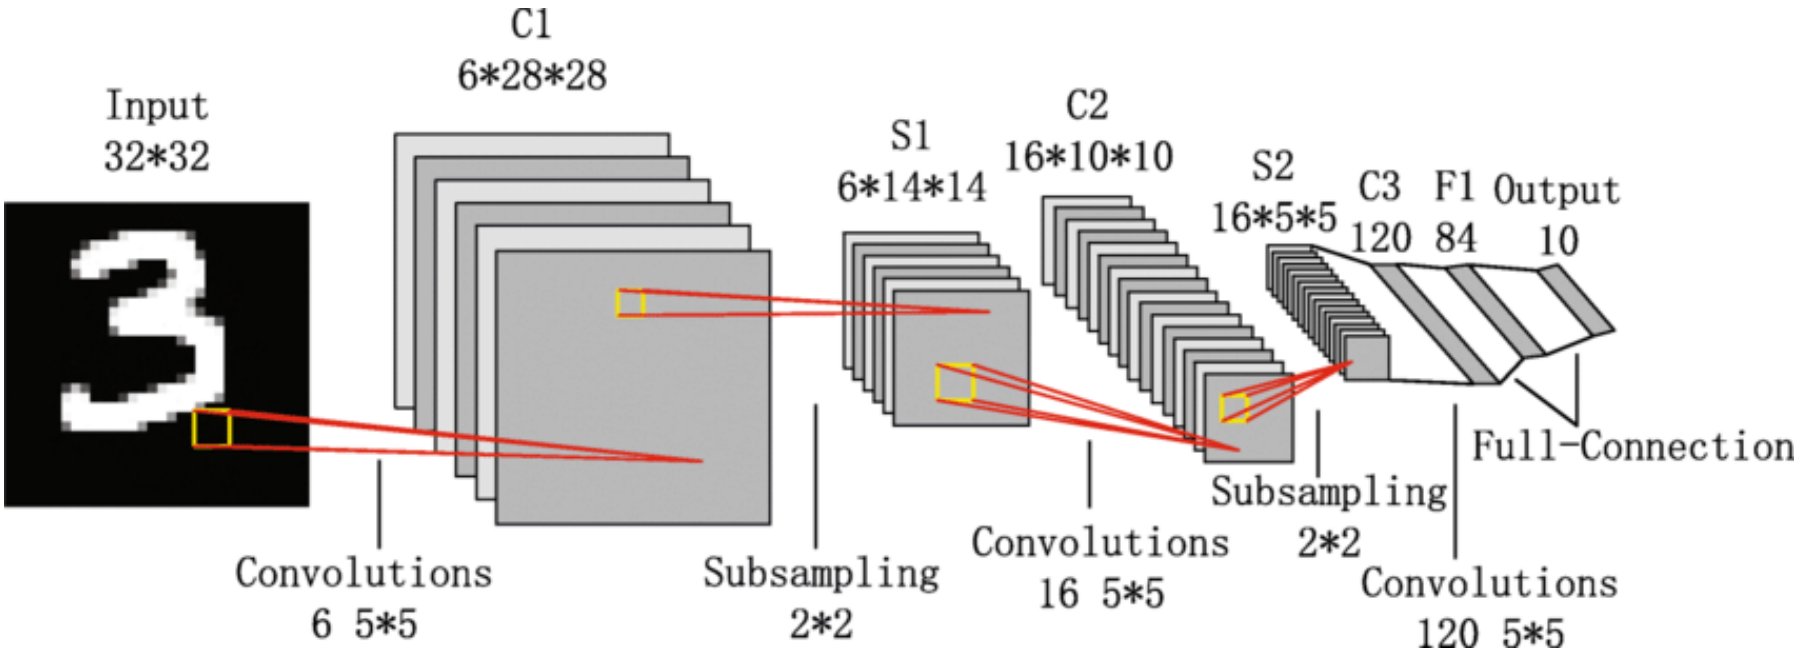
Input
32*32
C1
6*28*28
S1
6*14*14
C2
16*10*10
S2
16*5*5
C3
120
F1
84
Output
10
Full-Connection
Convolutions
6 5*5
Subsampling
2*2
Convolutions
16 5*5
Subsampling
2*2
Convolutions
120 5*5

Cấu trúc:

1. **Đầu vào**: 32×32×1
2. **C1**: Lớp tích chập (6 bộ lọc 5×5, stride 1) → 28×28×6
3. **S2**: Lớp gộp trung bình (2×2, stride 2) → 14×14×6
4. **C3**: Lớp tích chập (16 bộ lọc 5×5, kết nối đặc biệt) → 10×10×16
5. **S4**: Lớp gộp trung bình (2×2, stride 2) → 5×5×16
6. **C5**: Lớp tích chập hoạt động như FC (120 bộ lọc 5×5) → 1×1×120
7. **F6**: Lớp kết nối đầy đủ (84 nơ-ron)
8. **Output**: Lớp kết nối đầy đủ (10 nơ-ron, cho 10 chữ số)

Tầm quan trọng: Đặt nền móng cho CNN hiện đại, chứng minh hiệu quả của tích chập trong xử lý hình ảnh.

3. MỘT SỐ KIẾN TRÚC MẠNG CNN NỔI TIẾNG

AlexNet (2012)

Người phát triển: Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton
Đặc điểm chính:

- Giành chiến thắng trong cuộc thi ImageNet 2012, giảm lỗi từ 26% xuống 15.3%
- Sâu hơn LeNet nhiều, sử dụng GPU để huấn luyện
- Giới thiệu ReLU, Local Response Normalization, Dropout
- Số tham số: khoảng 60 triệu
- Kích thước đầu vào: 227×227×3 (ảnh RGB)

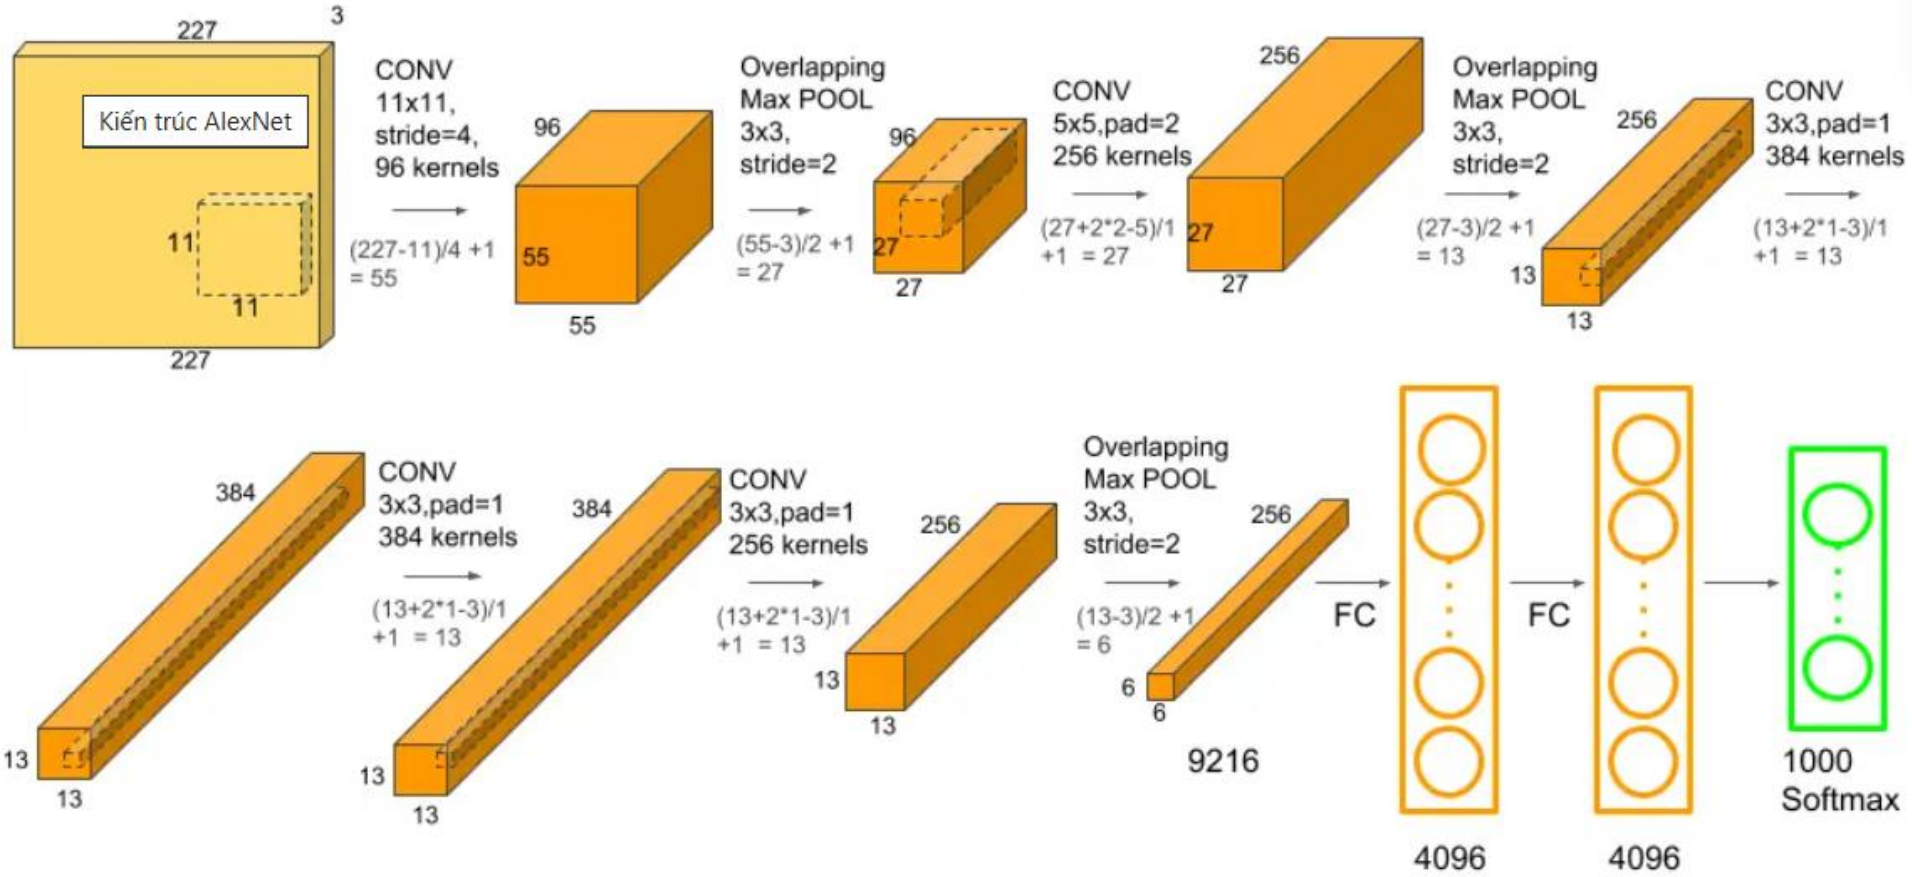
Kiến trúc AlexNet
227
227
3
11
11
CONV
11x11,
stride=4,
96 kernels
(227-11)/4 +1
= 55
96
55
55
Overlapping
Max POOL
3x3,
stride=2
(55-3)/2 +1
= 27
96
27
27
CONV
5x5,pad=2
256 kernels
(27+2*2-5)/1
+1 = 27
256
27
27
Overlapping
Max POOL
3x3,
stride=2
(27-3)/2 +1
= 13
256
13
13
CONV
3x3,pad=1
384 kernels
(13+2*1-3)/1
+1 = 13
384
13
13
CONV
3x3,pad=1
384 kernels
(13+2*1-3)/1
+1 = 13
384
13
13
CONV
3x3,pad=1
256 kernels
(13+2*1-3)/1
+1 = 13
256
13
13
Overlapping
Max POOL
3x3,
stride=2
(13-3)/2 +1
= 6
256
6
6
9216
FC
4096
FC
4096
1000
Softmax

Cấu trúc:

1. **Đầu vào**: 227×227×3
2. **Conv1**: Lớp tích chập (96 bộ lọc 11×11, stride 4, ReLU) → 55×55×96
3. **Pool1**: Max Pooling (3×3, stride 2) → 27×27×96
4. **Conv2**: Lớp tích chập (256 bộ lọc 5×5, padding 2, ReLU) → 27×27×256
5. **Pool2**: Max Pooling (3×3, stride 2) → 13×13×256
6. **Conv3**: Lớp tích chập (384 bộ lọc 3×3, padding 1, ReLU) → 13×13×384
7. **Conv4**: Lớp tích chập (384 bộ lọc 3×3, padding 1, ReLU) → 13×13×384
8. **Conv5**: Lớp tích chập (256 bộ lọc 3×3, padding 1, ReLU) → 13×13×256
9. **Pool5**: Max Pooling (3×3, stride 2) → 6×6×256
10. **FC6**: Lớp kết nối đầy đủ (4096 nơ-ron, ReLU, Dropout)
11. **FC7**: Lớp kết nối đầy đủ (4096 nơ-ron, ReLU, Dropout)
12. **FC8**: Lớp kết nối đầy đủ (1000 nơ-ron, Softmax)

Tầm quan trọng: Tạo nên cuộc cách mạng trong thị giác máy tính, khởi đầu cho kỷ nguyên deep learning trong xử lý hình ảnh.

3. MỘT SỐ KIẾN TRÚC MẠNG CNN NỔI TIẾNG

VGG-16 (2014)

Người phát triển: Visual Geometry Group (Đại học Oxford)

Đặc điểm chính:

- Kiến trúc đơn giản, sâu, đồng nhất
- Chỉ sử dụng bộ lọc 3×3, stride 1, padding 1
- Max pooling 2×2, stride 2
- Số tham số: khoảng 138 triệu
- Kích thước đầu vào: 224×224×3

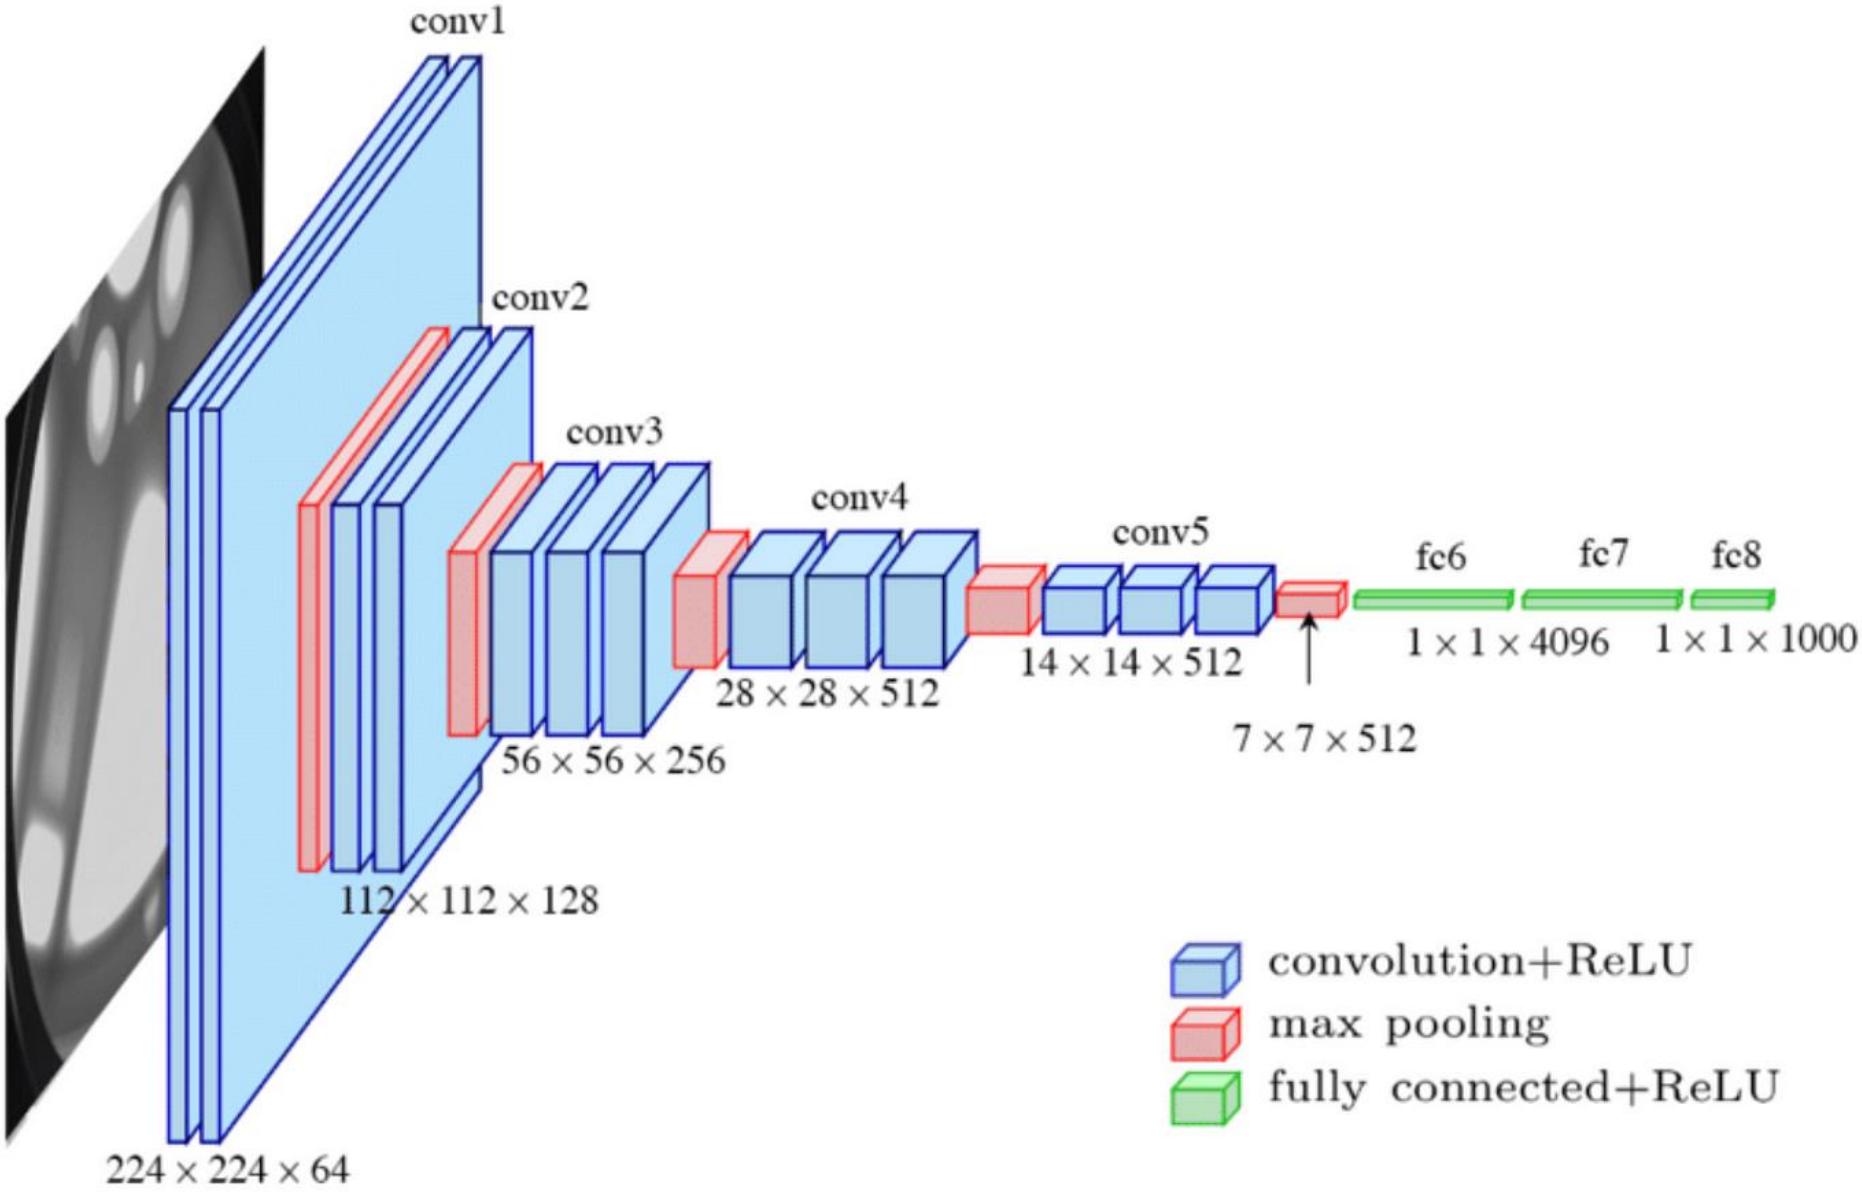
conv1
conv2
conv3
conv4
conv5
fc6
fc7
fc8
224 × 224 × 64
112 × 112 × 128
56 × 56 × 256
28 × 28 × 512
14 × 14 × 512
7 × 7 × 512
1 × 1 × 4096
1 × 1 × 1000
convolution+ReLU
max pooling
fully connected+ReLU

Cấu trúc:

1. **Đầu vào**: 224×224×3
2. **Block 1**: 2 lớp tích chập (64 bộ lọc 3×3, ReLU) → Max pool → 112×112×64
3. **Block 2**: 2 lớp tích chập (128 bộ lọc 3×3, ReLU) → Max pool → 56×56×128
4. **Block 3**: 3 lớp tích chập (256 bộ lọc 3×3, ReLU) → Max pool → 28×28×256
5. **Block 4**: 3 lớp tích chập (512 bộ lọc 3×3, ReLU) → Max pool → 14×14×512
6. **Block 5**: 3 lớp tích chập (512 bộ lọc 3×3, ReLU) → Max pool → 7×7×512
7. **FC1**: Lớp kết nối đầy đủ (4096 nơ-ron, ReLU, Dropout)
8. **FC2**: Lớp kết nối đầy đủ (4096 nơ-ron, ReLU, Dropout)
9. **FC3**: Lớp kết nối đầy đủ (1000 nơ-ron, Softmax)

Tầm quan trọng: Chứng minh tầm quan trọng của độ sâu mạng, tạo nên kiến trúc đơn giản nhưng hiệu quả cao.